01 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Freedom CQA

Руководство для выступления и демонстрации продукта • 8 ноября 2026

Как устроено решение.
Что нажимать на сайте.
Как отвечать на вопросы жюри.

Главная идея: система оценивает работу оператора по заданным правилам, объясняет выводы и даёт человеку возможность проверить и пересмотреть результат.

Внутри гайда	Где искать
Архитектура сайта и модели	Разделы 03-05
Разделы сайта, баллы, N/A, доказательства	Разделы 06-09
Чек-лист и апелляции: пошаговые действия	Разделы 09-10
Новые диалоги, контрольный набор, экспорт	Разделы 11-12
Сценарий защиты, вопросы, запуск	Разделы 02 и 13-15
Источники и финальная памятка	Раздел 16

Что важно сказать точно

- Веса Qwen сохранены. Это **базовая модель без дообучения**; наша работа - пайплайн оценки, RAG, проверки, API и продуктовый процесс.
- 65 оценок Kaggle импортированы: коммуникация обновлена до 43.1, остальные критерии сохранены из v42. Это **не 100% точность** и не экспертный Ground Truth.
- На Mac подготовлена отдельная ветка Ollama. Её устройство и результаты нужно отличать от Kaggle NF4.

Сайт: 127.0.0.1:8000
Приватный репозиторий: Daulet-coder/freedom-cqa

02 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Защита за 5 минут

В студенческом гайде указан максимум 5 минут. Если организаторы объявят другой регламент, пройдите полный процесс по разделам 07-13.

«Freedom CQA помогает контролю качества быстро найти проблемный разговор, понять причины оценки и провести прозрачный пересмотр. Покажу весь процесс на работающем интерфейсе».

Время	Действие на экране	Что произнести
0:00-0:40	Обзор → Диалоги	65 записей RU/KZ/EN; оценки, риски и охват. Средний балл - показатель диалогов.
0:40-1:40	DEV → Грубые ошибки → p1-ru-022	Раскрыть «Грубые ошибки», нажать реплику #10 / #12, проверить предложение услуги в обход компании.
1:40-2:30	p1-ru-001 → оценка и N/A	Раскрыть консультацию и завершение. Объяснить доказательства и перераспределение весов.
2:30-3:40	CUSTOM → Оспорить оценку → Апелляции	Выбрать критерий, подать комментарий, принять решение с причиной и показать итог.
3:40-4:40	Чек-лист → изменить → сохранить	Показать версию и передачу текущего правила в новую оценку. Для живого запроса использовать короткий CUSTOM.
4:40-5:00	История / Экспорт	Показать сохранение версий и валидированный JSON. Закончить на готовом результате.

Подготовьте заранее

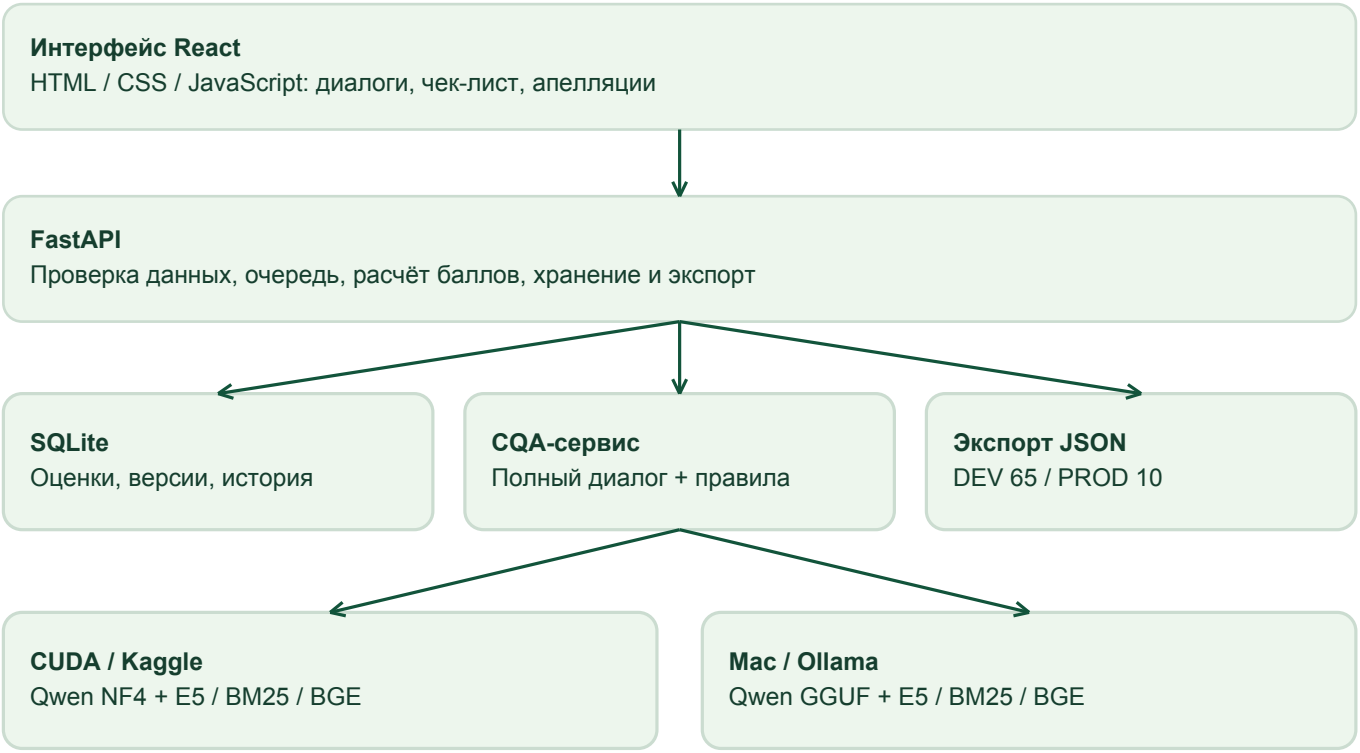
Откройте нужные диалоги, прогрейте локальную модель коротким запросом и измерьте время. Новый inference запускайте в начале показа; пока он работает, демонстрируйте уже сохранённые результаты и явно называйте их источник.

Слайды необязательны. Основной акцент - кликабельный работающий процесс. На вопросы жюри переходите к исходным сообщениям, а не только к итоговой цифре.

03 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Архитектура продукта

Сайт, API, хранение и модель выполняют разные задачи. Отдельный адаптер позволяет заменить способ запуска модели, сохранив интерфейс.



Компонент	За что отвечает
React / HTML / CSS	Показывает разговоры, аудио, критерии и формы. Отправляет действия пользователя в API.
FastAPI	Принимает импорт, запускает оценку, проверяет ответ модели, считает итог и обрабатывает апелляции.
SQLite	Сохраняет разговоры, настройки, задания обработки, результаты, историю и решения проверяющего.
CQA-сервис	Получает JSON {conversation, checklist}; возвращает значения критериев, причины и исходные номера реплик.
results.json	Формат передачи организаторам. Это выгрузка оценок, а не веса модели и не резервная копия всей системы.

В интерфейсе нет входа и вымышленного профиля сотрудника. Для демонстрации роли оператора и проверяющего показаны отдельными действиями; промышленное разграничение доступа пока не реализовано.

04 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Архитектура Kaggle 43.1

Qwen3.5-9B NF4 + RAG. Текущие 65 результатов: пересмотр коммуникации 43.1 поверх остальных оценок v42.

Шаг	Что происходит и зачем
1. Исходный диалог	Сохраняются роли, язык, время и порядок сообщений. Оценивается оператор; client, bot и system дают контекст.
2. Наблюдаемые факты	Qwen извлекает факты о начале, уточнениях, идентификации и завершении. Для стандартных правил код проверяет эти факты и их расположение в разговоре.
3. Поиск FAQ (RAG)	Запросы к базе знаний находят кандидатов: E5 ищет по смыслу, BM25 - по словам. В корпусе 530 зафиксированных FAQ-фрагментов.
4. Переранжирование	BGE reranker сравнивает запрос с найденными фрагментами и меняет порядок кандидатов, чтобы отобрать более релевантные.
5. Коммуникация 43.1	Эмпатия выделена в отдельный этап: недовольство клиента, невежливость оператора и реакция на конкретное неудобство. Проверяются роли исходных реплик. Ведение и грубые ошибки оцениваются отдельно; узкая проверка выявляет повторный вопрос об уже указанной платформе.
6. Проверка ответа	Проверяются ID, типы, допустимые значения, объяснения и исходные номера реплик. При неудаче сохраняется ошибка, а не вымышленная оценка.
7. Баллы и аудит	Код считает итог по весам и N/A. Частичный refresh пересчитывает коммуникацию, сохраняя остальные критерии v42. Manifest фиксирует этапы и ошибки. Это не полный повторный прогон всех критериев 43.1.

RAG - это поиск материалов и добавление их в контекст модели. Он не меняет нейросетевые веса. Отсутствие ответа в найденной подборке само по себе не доказывает ошибку оператора.

Это гибридный процесс: LLM + поиск + программные проверки. Не говорите, что «одна нейросеть сама выставляет итоговую цифру без правил».

05 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Веса, компоненты и две ветки

Термин	Понятное объяснение
Qwen3.5-9B	Базовая языковая модель: интерпретирует разговор и формулирует выводы. В проекте используется текст диалога.
NF4 / GGUF Q4_K_M	Разные форматы и способы квантизации - компактного представления параметров. Квантизация не равна дообучению.
E5 embeddings	Числовые представления смысла текста для поиска FAQ. В сохранённых assets размерность - 768.
BM25	Лексический поиск по словам и их редкости. Это алгоритм поиска, а не модель генерации ответа.
BGE reranker	Повторно оценивает релевантность пары «запрос + найденный текст». Сам не выставляет CQA-балл.
Вес критерия	Например, 20 баллов за консультацию. Это вклад правила в расчёт, а не параметр нейросети.

Сайт и локальную модель запускаем на MacBook через Ollama. На Apple M4 Pro используется Metal GPU. Общая логика CQA 43.1 подключается через адаптер: Qwen генерирует на GPU, E5 и BGE работают на CPU.

Kaggle и Mac - сравнение

	Kaggle / CUDA	Mac / Ollama
Генератор	Qwen NF4	Qwen GGUF Q4_K_M
Поиск	E5 + BM25 + BGE	E5 + BM25 + BGE на CPU
Логика	Многоэтапный 43.1; результаты частично обновлены с v42	Общий cqa_runtime 43.1; генерация через Ollama
Статус	65 оценок: коммуникация 43.1 + baseline v42	Новый запрос успешно проверен
Обучение	Базовые веса	Базовые веса

Локальный NF4-чекпойнт проверен: 10 файлов, 4 safetensors shards, 7 660 361 799 байт; SHA-256 совпадают с манифестом. Его нельзя просто открыть в Ollama: GGUF скачивается отдельно. На Mac обнаружен Apple M4 Pro через Metal. Новый многоэтапный 43.1 прошёл короткий запрос примерно за 32 секунды: 8 критериев, 3 FAQ-фрагмента, без ошибок поиска. Это единичная проверка, не гарантия скорости или точности.

06 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Что уже сделали и как проверяли

Область	Реализовано
Интерфейс	Корпоративная зелёная символика, логотип Freedom, заметные подписи, аудиобар, адаптивная компоновка.
Оценка	Исходные транскрипты RU/KZ/EN, 8 критериев, объяснения, доказательства, N/A, отдельный флаг грубой ошибки.
Полный процесс	Новые диалоги, очередь и прогресс, отмена оставшихся запросов, чек-лист с версиями, апелляции и история.
Интеграция	CUDA-адаптер, проверка весов, импорт Kaggle, отдельный Ollama-адаптер, проверка подключения без скрытой подмены демо.
Сдача	Раздельные DEV / PROD, проверка полноты и структуры, официальный JSON, README, исходники и приватный GitHub.

Какие показатели можно заявлять

- **65/65 без ошибок исполнения** для сохранённого v42: проверены структура, значения, доказательства и пересчёт. Это полнота обработки, а не совпадение с экспертами.
- **40 автоматических проверок** приложения и адаптеров проходят. Синтетические fixtures проверяют код и контракт, а не умение модели оценивать речь. GitHub Actions также прошёл.
- **RAG: top-3 с 5/10 до 9/10, MRR с 0,4434 до 0,6833** на малой диагностической подборке разработчиков. Это не независимая метрика CQA.

Точность относительно полного независимого Ground Truth не измерена. Не выдавайте средний балл, долю успешных запросов или RAG top-3 за точность AI-оценки.

Что остаётся ограничением: спорные смысловые решения модели, отдельная проверка RU/KZ/EN, отсутствие промышленной авторизации, ASR и оценки эмоций в основном веб-процессе.

07 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Карта сайта: куда заходить

Раздел	Назначение	Что показывать жюри
Обзор	Сводка загруженных наборов и результатов, быстрые переходы.	Охват, количество разговоров и переход к проблемным диалогам.
Диалоги	Список, поиск, фильтры, импорт и запуск оценки.	DEV / PROD / CUSTOM / DEMO; язык; грубые ошибки; новые результаты.
Карточка диалога	Транскрипт, аудио, баллы, доказательства, история.	Раскрыть критерий, нажать «Реплика», показать реальный контекст.
Чек-лист	Правила, вес, тип ответа, шкала и N/A.	Изменить критерий и применить его новым запросом.
Апелляции	Обращения о несогласии и решения проверяющего.	Комментарий → проверка реплик → решение → итог.
Аналитика	Сводные показатели сохранённых оценок.	Распределение баллов и зон риска, без заявлений о точности.
Модель и данные	Режим, URL, имя модели, тайм-аут, команда, health-check.	Фактический источник новых оценок и доступность сервиса.

Зачем нужны разные режимы

demo: простые правила для репетиции интерфейса, без нейросети; в сдачу не допускаются. **local:** собственная модель, сейчас Qwen через Ollama. **external_api:** внешний AI-сервис. **hybrid:** сочетание локальной и внешней обработки. Выбор режима маркирует источник оценки; сам переключатель не скачивает и не обучает модель. Реальную обработку задаёт подключённый CQA-сервис.

Что означают наборы

DEV: 65 исходных записей организаторов, 60 синтетических чатов и 5 реальных звонков; 35 RU, 15 KZ, 15 EN. **PROD:** 10 новых контрольных чатов. **CUSTOM:** собственные репетиции. **DEMO:** примеры интерфейса с явной пометкой.

Уже сохранённый результат может быть импортирован из Kaggle, даже если активный сервис новых запросов - Ollama. Переключение режима не переименовывает и не пересчитывает старые оценки автоматически.

08 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Как читать карточку диалога

1. Источник результата

Проверьте ID, набор и пометку: «Импортированный результат», «Результат модели» или «Демонстрационная оценка». В истории видны прошлые версии и их происхождение. Для ошибки обработки нет обычного итогового балла.

2. Аудиобар и расшифровка

- У звонка можно включить запись, поставить паузу, изменить скорость и перемотать. Кнопки «Реплика #…» переводят к исходному сообщению и соответствующему времени.
- Поиск по расшифровке: Enter - следующий найденный фрагмент, Shift+Enter - предыдущий. Выбранная реплика выделяется.
- При отсутствии записи доступен исходный текст. Локально прикреплённый файл не отправляется на сервер и после обновления страницы прикрепляется заново.
- Без декодированного аудио полосы показывают схему активности по времени. Это не измерение интонации или разделение голосов алгоритмом ASR.

3. Оценка качества

Раскройте строку критерия. Покажите значение, баллы / вес, причину и доказательства. Номера идут с 1 по **всем** исходным сообщениям: client, operator, bot, system. Реплика бота не является действием человека-оператора.

4. Что означает N/A

> «Нет» - действие требовалось, но не выполнено. N/A - критерий неприменим по конкретному разрешённому условию. Нельзя ставить N/A просто потому, что модель не уверена.

Для пропущенного действия доказательство - участок, где оно ожидалось. Для N/A объяснение должно указывать условие неприменимости. Всегда проверяйте контекст, а не только красивую формулировку модели.

09 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Чек-лист и расчёт баллов

Чек-лист - общая конфигурация правил. Критерий описывает, что проверять, тип - как отвечать, вес - сколько это даёт в итоге.

Критерий	Ответ / шкала	Вес
Контакт: приветствие и представление в первом ответе	Да / Нет	10
Потребность: нужные уточнения до ответа	Да / Нет / N/A	15
Идентификация до защищённого действия	Да / Нет / N/A	20
Корректность и полнота консультации	0, 5, 10, 15, 20 / N/A	20
Эмпатия и клиентоориентированность	Да / Нет	15
Ведение, скорость, грамотность	0, 4, 7, 10	15
Завершение: итог / помощь и прощание	Да / Нет / N/A	5
Грубые ошибки	Да / Нет, отдельный флаг	0

Расчёт на понятном примере

Бинарное «Да» даёт полный вес, «Нет» - 0. Для шкалы: **баллы = значение / максимум шкалы × вес**. Например, ведение 7 из 10 при весе 15 даёт 10,5 балла.

> Итог = 100 × сумма полученных баллов / сумма весов применимых критериев. Округление - до двух знаков.

У сохранённого p1-ru-001: потребность и идентификация отмечены N/A. Применимый вес - 65, получено 60. Итог: 100 × 60 / 65 = **92,31**. Это пример расчёта по сохранённой оценке, не подтверждение её экспертной правильности.

Грубое нарушение: оскорбление клиента, платная услуга в обход компании или раскрытие конфиденциальной информации. Флаг не обнуляет итог автоматически. Порог первой реакции 3 минуты, теги и вложения в этот чек-лист не входят.

10 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Как менять чек-лист

Шаг	Действие
1	Откройте «Чек-лист». Выберите нужную строку или нажмите «Добавить критерий».
2	Заполните уникальный ID, название и точное правило: что считается выполнением, нарушением и неприменимостью.
3	Выберите тип: Да / Нет, числовая шкала или флаг. Для шкалы задайте разрешённые ступени и положительный максимум.
4	Укажите вес. Для флага нарушения вес 0. N/A включайте только вместе с явным условием применения.
5	Нажмите «Сохранить изменения». Появится новая версия; уже полученные результаты сохранят свой прежний чек-лист.
6	Откройте короткий CUSTOM и запустите оценку заново. Покажите в новой версии, как применилось новое правило.
7	После эксперимента верните «Официальный чек-лист», если готовите официальную выгрузку из 8 критериев.

Пример критерия для демонстрации

ID: next_step_clarity
Тип: Да / Нет, вес 5
Правило: «Если запрос не решён, оператор назвал конкретный следующий шаг. Общая фраза без понятного действия не засчитывается. Если запрос полностью решён, критерий неприменим».
N/A: разрешить.

Это пример дополнительного пользовательского правила, не замена официального критерия. Для убедительного показа используйте разговор, в котором условие явно применимо. Если правило оценивается неверно, это повод показать доказательства и пересмотр, а не скрывать результат.

Сохранение формы само по себе не доказывает, что новая инструкция осмысленно применена. Нужен новый inference. При обработке очередь защищает чек-лист и настройки от одновременного изменения. Полное совпадение правил важнее метки версии разных хостов.

11 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Апелляция: зачем и как

Апелляция - сохранённый запрос человека пересмотреть конкретный критерий. Она не означает автоматическое признание ошибки AI и не обучает модель.

Сначала - действие оператора

1. Откройте оценённый разговор и раскройте спорный критерий.
2. Нажмите «Оспорить оценку». Выберите критерий.
3. Опишите, с чем не согласны, какой фрагмент это подтверждает и какое правило следует применить.
4. Отправьте обращение. Оно появится в разделе «Апелляции».

Хороший комментарий:
«Прошу пересмотреть завершение. В реплике #6 оператор предложил дальнейшую помощь, в #8 попрощался. По правилу считаю ответ “Да”. Прошу проверить эти фрагменты».

Номера здесь условные: перед отправкой подставьте номера реального диалога.

Затем - действие проверяющего

5. В «Апелляциях» откройте обращение. Прочитайте комментарий, исходную оценку и доказательства.
6. Подтвердите оценку либо выберите новое разрешённое значение.
7. Напишите причину решения. Например: «Подтверждаю: в указанной реплике нет ни итога, ни предложения помощи» - только если это верно по тексту.
8. Сохраните решение и вернитесь к карточке: итог пересчитан, исходное значение и решение доступны в истории.

Что показать в презентации

- Проведите апелляцию на CUSTOM, чтобы не менять файл DEV, который уже готов к сдаче.
- Покажите обе роли и оба исхода: оценка может быть подтверждена или изменена. Для изменения не требуется соглашаться с моделью.
- Незавершённое обращение блокирует переоценку этого разговора и официальный экспорт набора. История сохраняется и после следующей оценки.

12 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Как оценить новый разговор

Импорт и запуск

1. «Диалоги» → «Загрузить диалоги». Для репетиции выберите CUSTOM; для контрольных данных - PROD.
2. Загрузите JSON организаторов с data.records, массив записей или один разговор.
3. Убедитесь, что ID, язык, канал, роли и время сохранились.
4. Откройте запись → «Оценить диалог». Для группы используйте фильтры и «Оценить выборку».
5. Следите за очередью, текущим ID, количеством завершённых запросов и ошибками.
6. Откройте результат, проверьте причины, доказательства и актуальность чек-листа.

Минимальный формат

```
{
"conversation_id": "custom-new-001",
"language": "RU", "channel": "agent chat",
"audio_url": null,
"transcript": [
{"timestamp":"00:00", "speaker":"client", "text":"Здравствуйте"},
{"timestamp":"00:05", "speaker":"operator",
"text":"Здравствуйте! Меня зовут Алина. Чем помочь?"}
]
}
```

Для демонстрации есть docs/presentation-practice.json. Повторный собственный импорт требует нового уникального ID: существующие записи не перезаписываются. **В PROD исходные ID менять нельзя.**

Что делать с ожиданием и ошибкой

Отмена очереди прекращает оставшиеся запросы после текущего. Уже завершённые результаты сохраняются. Если сервер перезапущен, очередь помечается прерванной. Ошибка inference сохраняется явно; она не равна нулю и не подменяется демо-правилами.

13 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Контрольные данные и сдача

Этап	Что проверить
DEV	65 исходных ID: 60 чатов и 5 звонков. results/dev/results.json уже сохранён и включён в репозиторий.
PROD	Загрузить все 10 выданных контрольных чатов, сохранить их ID, применить действующий официальный чек-лист.
Валидация	Все ID уникальны, каждый результат содержит все 8 критериев. Типы, шкалы, доказательства, N/A и итог корректны.
Экспорт	Открыть «Экспорт», выбрать DEV / PROD, проверить готовность, скачать или сохранить results.json.
Публикация	Проверить team_name и фактические model.mode / model.name. Выполнить commit и push до объявленного стоп-кода.

Где должны лежать результаты

```
results/dev/results.json
results/prod/results.json
```

Корневые поля: schema_version = "1.0", team_name, model, results. Для ошибки: исходный conversation_id, status = "error", criteria = [], score = null, error с причиной. В PROD должно быть ровно 10 записей, включая ошибки.

Что блокирует официальный экспорт

Недостающие оценки, DEMO-результаты, несоответствие текущим правилам, экспериментальные ID / веса / шкалы, незакрытые апелляции и выполняющаяся обработка. CUSTOM и DEMO не подмешиваются в основной набор. Черновик не равен файлу для сдачи.

Репозиторий сейчас PRIVATE по вашему запросу. В выданном гайде организаторов требуется открытый репозиторий к сдаче. Заранее согласуйте доступ; менять видимость без решения владельца нельзя.

Сайт сохраняет файл локально, но не выполняет commit/push автоматически. Секретные ссылки и токены в Git не включены; большие модельные веса остаются локально.

14 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Ответы на вопросы жюри

Вы обучили свою нейросеть?

Мы используем базовую Qwen3.5-9B без fine-tuning. Разработали конфигурируемый CQA-пайплайн, поиск FAQ, проверки, адаптеры и полный интерфейс оценки и пересмотра.

Как проверить, что это не заготовленные ответы?

Загрузим новый разговор с новым ID, запустим активный сервис, покажем очередь, полученные причины, номера реплик и историю. Импортированные результаты Kaggle подписаны отдельно.

Как изменяется критерий без изменения кода?

Сохраняем его правило, тип, шкалу и вес в интерфейсе. Новая конфигурация отправляется CQA-сервису. Для применения запускаем новую оценку.

Что если модель ошиблась или данных мало?

Проверяем исходный контекст. N/A используем только по разрешённому условию. Техническую ошибку сохраняем отдельно. Смысловой спор отправляем на апелляцию человеку.

Почему RAG и что он даёт?

Продуктовые утверждения нужно сверять с материалами компании. Поиск отбирает FAQ, reranker уточняет релевантность, модель получает контекст. RAG уменьшает зависимость от памяти модели, но не гарантирует отсутствие ошибок.

Какая точность и стоимость?

Полной независимой CQA-метрики пока нет. Успех 65 запросов - полнота исполнения. Для локального inference нет платы облачному API за токены; время и ресурсы оборудования измеряются отдельно.

Почему результат Mac может отличаться?

На Mac используется тот же многоэтапный runtime 43.1 и E5/BM25/BGE, но генерация идёт через GGUF/Ollama вместо NF4/CUDA. Отличия квантизации и генератора могут менять ответы. Качество сравниваем на одной экспертной выборке.

15 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Запуск и устранение проблем

Два терминала VS Code

Терминал 1: модель

```
cd /Users/daulet/Documents/Freedom
./start_model_mac431.command
```

Терминал 2: сайт

```
cd /Users/daulet/Documents/Freedom
./start.command
```

В «Модель и данные»: local; URL http://127.0.0.1:9001/evaluate; имя Qwen GGUF + E5/BM25/BGE, CQA 43.1; timeout 900. Сохранить → «Проверить подключение» → оценить короткий новый CUSTOM. Health-check подтверждает доступность сервиса; полный запрос проверяет inference.

Ситуация	Что сделать
Первое сообщение о порте 11434	Сервер мог ещё запускаться. В исправленном скрипте начальная проверка скрыта; при реальном отказе смотрите work/ollama.log.
Сайт не открывается	Проверить терминал start.command и адрес 127.0.0.1:8000. Не запускать второй сервер на уже занятом порту.
Модель недоступна	Проверить терминал модели, /health на 9001 и URL в настройках. Сохранённые SQLite-настройки имеют приоритет над env.
Долго / не хватает памяти	Посмотреть прогресс и фактический режим CPU/GPU. Использовать короткий разговор, дать прогреться. Не обещать фиксированную скорость без замера.
Нет аудио	Ссылка может быть недоступна; использовать исходный транскрипт или прикрепить локальный файл. Это не запускает ASR автоматически.
Экспорт не готов	Открыть список причин: отсутствующие результаты, старая конфигурация, ошибка формата, незакрытая апелляция или активная очередь.

Встроенный GPU Apple работает через Metal, а не CUDA. В текущем запуске после старта из терминала обнаружен M4 Pro. Проверить распределение после загрузки модели: work/runtime/ollama/ollama ps. Оба терминала оставлять открытыми.

16 / ПРАКТИЧЕСКОЕ РУКОВОДСТВО

Памятка перед выходом и источники

За 10 минут до выступления

- Сайт открывается; сервер модели отвечает; новый короткий CUSTOM успешно оценён.
- Вы понимаете источник каждой показанной оценки: Kaggle, Ollama или DEMO.
- Для нарушения подготовлен p1-ru-022; для N/A и расчёта - p1-ru-001.
- Проверены кнопки перехода к реплике, история, аудио у выбранного звонка.
- Апелляцию репетируете на CUSTOM; перед сдачей нет открытых обращений.
- Официальный чек-лист восстановлен; готовность экспорта DEV проверена.
- PROD - только выданные 10 ID. Файл сохранён, закоммичен и отправлен до стоп-кода.
- Проверены team_name и доступ организаторов к репозиторию; секретов в нём нет.
- Уложились в 5 минут; знаете, какой шаг показать по просьбе жюри.

Основания и материалы

Выданные организаторами документы: CQA_Hackathon_Student_Guide_v3 1.pdf (4 стр.); CQA_Chat_Quality_Checklist.pdf (3 стр.); CQA_Student_Guide_Appendix_Results.pdf (3 стр.). Условия презентации и комментарии организаторов из переписки использованы как требования к демонстрации, а не как разрешение менять настройки доступа.

Фактическая реализация: backend/main.py, backend/scoring.py, backend/workspace.py; frontend/app.jsx и workspace.jsx; model_service/worker.py, cqa_runtime.py, service.py, ollama_service.py; MODEL_INTEGRATION.md; release_manifest.json и checkpoint_manifest.json. Состояние проверено 8 ноября 2026.

Qwen3.5-9B: официальная модель

E5: semantic embeddings

BGE: reranker

Ollama: поддержка macOS / Apple Silicon

Исходники Freedom CQA

На защите лучший ответ на спорный балл - открыть правило, исходную реплику и объяснение, а затем показать прозрачный процесс пересмотра.